

ParmBot: Un agente virtual para la lectura de noticias

André Salas-Chinchilla *ECCEI*
Universidad de Costa Rica
 San José, Costa Rica
 andre.salaschinchilla@ucr.ac.cr

Resumen—En la actualidad, existe una gran cantidad de información y perspectivas en las noticias de internet, lo que vuelve difícil mantenerse informado de lo que sucede en el mundo. Se presenta un agente virtual con la capacidad de buscar noticias, resumirlas y conversar al respecto, presentando diferentes perspectivas y discutiendo al respecto con el usuario. Se crea un agente con la capacidad de buscar noticias mediante NewsAPI.ai y con esto poder revisar noticias, presentarlas en una forma resumida y mantener una conversación respecto a las noticias con el usuario, todo esto mediante Gemini. Se realizan pruebas dándole uso libre del agente a 6 estudiantes de la ECCEI y dividiendo a estos en 2 grupos, el primero utiliza una versión interactiva del agente con avatar y capacidad de conversación, el segundo solamente una aplicación de CLI con la capacidad de generar resúmenes. Los 2 grupos realizan los test UES-SF y una versión modificada de TAM3. Los resultados de los cuestionarios muestra que la presencia de interacción con el agente genera mayor compromiso y aceptabilidad en el usuario, pero debido al tamaño de la muestra estos resultados no necesariamente representan a toda la población de estudiantes de la ECCEI.

Index Terms—Inteligencia artificial, resumen de noticias, agentes virtuales, chatbots

I. INTRODUCCIÓN

EN la actualidad, existe una gran cantidad de información y perspectivas en las noticias de internet. Estas noticias se encuentran en cientos o miles de sitios y artículos diferentes, dificultando el proceso de analizar y comparar la información que presentan. Esta dificultad significa que no siempre es posible estar completamente al día e informado con los eventos que pasan en el mundo.

La enorme cantidad de información dificulta enormemente que las personas puedan mantenerse correctamente informadas, especialmente estudiantes y asalariados u otras personas que no tengan el tiempo o la energía de revisar toda la información disponible. Esto puede ser problemático a la hora de formar opiniones sobre temas importantes como política o economía, creando una situación en la que diferentes personas forman su punto de vista desde diferente información o en algunos casos sin ninguna información. Esto es un gran problema en una sociedad democrática, donde la diferencia en información puede dificultar el debate y el entendimiento entre quienes reciben datos contradictorios.

Se han presentado diferentes soluciones a este problema, incluyendo sistemas como el chatbot con capacidad de resumir presentado en el artículo por Sufi & Alusami [1] y los resúmenes hechos con inteligencia artificial presentado por

Pozzi et al. [2]. Las soluciones con mayor similitud al proyecto presente son los chatbots que discuten noticias de un periódico específico, estos son discutidos en el artículo de Sánchez-Muñoz et al. [3] y el artículo de Nordberg et al. [4] en el que se crea un chatbot con la capacidad de mantener conversaciones sobre noticias actuales.

La mayor limitación de las soluciones presentadas son la falta de un verdadero agente virtual, esto puede verse en las herramientas que solamente pueden crear resúmenes de artículos y el centrarse ya sea en noticias sobre temas específicos o de un sitio web o periódico específico como los chatbots de El País y El Espectador [3]. Solamente la solución de Nordberg et al. [4] presenta un sistema que permite mantener conversaciones sobre cualquier tema, pero igualmente, su investigación se limita al lenguaje inglés.

Con esto en mente, se propone ParmBot, un chatbot de noticias. ParmBot tiene la capacidad de buscar noticias relevantes en internet de diferentes fuentes, resumirlas y llevar a cabo conversaciones sobre las mismas con un usuario. Para evaluar la utilidad y atractividad de este agente, se llevará a cabo una prueba piloto y una serie de cuestionarios para conocer la opinión de usuarios respecto a esta herramienta.

I-A. Preguntas de Investigación

- **RQ1:** ¿Cómo afecta la interacción con el agente en el compromiso del usuario?
- **RQ2:** ¿Cómo cambia la aceptabilidad de la herramienta con la presencia de interacción con el agente?

I-B. Objetivos

- **Rol:** El agente tiene el rol de ser un asistente, debe presentar la información al usuario de forma resumida pero sin agregar o eliminar datos y luego discutir sobre la misma con el usuario, todo esto durante una conversación en español.
- **Contexto de uso:** El agente debe ser usado para discutir noticias, esta destinado principalmente a personas estudiantes que debido a otras responsabilidades no siempre tienen el tiempo o la energía de mantenerse al día con todos los eventos que ocurren ni con las diferentes perspectivas sobre los mismos. El agente permitirá a estas personas no solo recibir resúmenes de los eventos, sino también hacer preguntas para aclarar detalles según lo vean necesario.

II. ANTECEDENTES

II-A. Agentes Web

El artículo de Ning et al. [5] es un resumen del estado de los agentes de IA enfocados en internet (agentes web). El artículo explica los diferentes tipos de agentes web, el proceso de crear, entrenar y refinar un agente, su uso y sus posibles riesgos. Este artículo no afecta directamente la metodología, pero es una base teórica importante para definir las limitaciones y objetivos de ParmBot.

II-B. Resúmenes creados por inteligencia artificial

El artículo de Shukla et al. [6] compara diferentes de IA según su capacidad para generar resúmenes de documentos legales. Se utilizan modelos supervisados y no supervisados, extractivos y abstractivos e incluso se hace fine-tuning para lograr mejores resultados. Se concluye que el modelo Legal-Pegasus, un modelo entrenado para sintetizar texto legal es la herramienta optima. Esta investigación es importante debido a que muestra la importancia de usar modelos especializados para tareas de síntesis.

La investigación de Tam et al. [7] evalúa la forma en la que los LLM clasifica resúmenes según que tan verídicos son. Se realiza un experimento en el que a un LLM se le presenta un texto original y 2 resúmenes y se le pide que elija cual de estos es más verídico. El experimento mostró que los LLM tienden a acertar correctamente cuál es más verídico, pero pueden ser engañados si el resumen de menor calidad está escrito en el documento original. Este artículo muestra algunos fallos que tienen los LLM a la hora de evaluar la calidad de un resumen, estas limitaciones deben tomarse en cuenta a la hora de generar los resúmenes usados por ParmBot.

Deroy et al. [8] realizaron una investigación similar a la de Shukla et al. [6]. Esta investigación también se basa en crear resúmenes de documentos legales utilizando modelos de IA. La mayor diferencia se encuentra en el interés presentado por disminuir las alucinaciones de los modelos, además del uso de modelos generales como GPT-3.5. Se concluye que los modelos generales también son capaces de mostrar buenos resultados, pero es necesario realizar un proceso de mitigación para disminuir las eliminaciones, se propone ingeniería de prompts para lograrlo. La investigación muestra que el uso de LLMs generales genera buenos resultados, pero la mitigación de alucinaciones podría mejorarse para disminuir aún más la aparición de datos falsos.

En cuanto a modelos especializados en el lenguaje español, Vogel-Fernández et al. [9] crearon un modelo llamado esT5s, entrenado directamente para analizar textos en español. El modelo es entrenado basándose en mT5 (un modelo multi-lenguaje), eliminando sus capacidades para otros idiomas y entrenándolo con texto en español. esT5s logra resultados similares a los de modelos mucho más grandes utilizando menos recursos, lo que lo vuelve viable para uso de un usuario común. La importancia de la investigación se encuentra en que enseña la viabilidad de resumir textos en español, idioma que, como es mencionado en el artículo, suele quedar de lado frente al inglés.

II-C. IA para resúmenes de noticias

Pozzi et al. [2] crearon un modelo llamado Cryptoblend, que tiene la capacidad de crear resúmenes de noticias sobre criptomonedas. Cryptoblend logra revisar múltiples artículos de su dataset para crear un solo resumen, un avance importante. La investigación logra llegar a un resumen coherente el 86.8 % de las veces. Los principales límites de este modelo son su uso de artículos puramente de su set de datos y el avance que se ha dado en la IA desde 2023, pero igualmente presenta una forma de crear resúmenes a partir de diferentes textos con un tema en común.

El artículo de Compaore et al. [10] explora la viabilidad de utilizar modelos LLM para crear resúmenes de noticias en francés. Se utilizan GPT-3.5 Turbo y Pegasus Summarizer para crear un resumen de una serie de noticias encontradas en internet. El modelo creado logra sintetizar los artículos dados, pero se concluye que aún puede mejorar. Este artículo es útil para esta propuesta debido a que muestra la viabilidad de la creación de resúmenes a partir de modelos de IA.

La investigación de Pan et al. [11] demuestra muchas formas diferentes de disminuir las alucinaciones en los resúmenes de noticias en español generados por LLM. Se realizan experimentos con diferentes tipos de prompting, estas revisiones culminan en un método llamado bottleneck prompting. Bottleneck prompting funciona dándole al modelo la instrucción junto a ejemplos del producto deseado, el modelo retorna una serie de puntos clave del texto original que luego son analizadas por modelos basados en BERT que encuentran entidades en el texto y generan relaciones entre las mismas a partir de las cuales genera un resumen final. Esta investigación es importante debido a que enseña una arquitectura muy útil para generar buenos resúmenes de noticias en español, un aspecto fundamental del funcionamiento de ParmBot.

Maheshwari et al. [12] escribieron un artículo centrándose en crear un modelo que resume noticias disminuyendo alucinaciones y manteniendo la neutralidad, este modelo se llama NewsLensAI. El modelo funciona utilizando creando una lista de entidades importantes y dándosela a la LLM junto al texto que debe resumir, lo cual hace que el modelo se apegue más al texto original. Esta investigación es importante debido a que muestra una forma de hacer que la LLM disminuya alucinaciones y aumente su neutralidad sin necesidad de cambiar su arquitectura.

El artículo de Segarra-Soriano et al. [13] se centra principalmente en la creación de un dataset para entrenar la creación de resúmenes de noticias en español y catalán (llamado DACSA), pero también hacen evaluación de sistemas de sintetización sobre el nuevo dataset. Los mejores resultados al resumir DACSA se dan en los modelos mT5 y Oracle, pero igualmente solo logran llegar a un BERTScore de 77.45, por lo que una mejora sigue siendo posible. La importancia de esta investigación es que muestra que, a pesar de buenos resultados, aún se puede mejorar enormemente la capacidad de estos modelos para resumir.

II-D. Chatbots de noticias

Zhang et al. [14] presentan una serie de recomendaciones de diseño a la hora de crear un chatbot de noticias. Se realiza un experimento donde 10 usuarios utilizan chatbots de diferentes noticieros mundiales y luego son entrevistados respecto a su preferencia y las ventajas y desventajas observadas en los sistemas, a partir de esto se deciden aspectos importantes a tomar en cuenta para el diseño de un modelo similar. Los resultados muestran que un chatbot debe ser: relevante, actualizado, rápido, humano y debe tener más funciones que resumir artículos de noticias. Estos resultados brindan puntos importantes al tomar en cuenta si se desea crear un chatbot que sea aceptado y utilizado por los usuarios, por lo que es importante para el proceso de diseño de ParmBot.

El artículo de Nordberg et al. [4] se explora el uso de los chatbots de noticia y consideraciones a la hora de diseñar estos sistemas. Se menciona la importancia de mantener acceso a diferentes fuentes, permitir diferentes niveles de interacción (preguntas rápidas o largas conversaciones) y mantener la credibilidad de la herramienta. Se hace una prueba con un modelo que logra entablar conversaciones sobre eventos, este da buenos resultados a pesar de la tendencia de la LLM de alucinar. Este artículo es importante debido a que presenta una base metodológica para el diseño del agente y muestra la viabilidad del mismo.

Sánchez-Muñoz et al. [3] realizaron una investigación respecto a los chatbots lanzados por los periódicos El Espectador y El País. Estos periódicos crearon un chatbot basándose en los modelos dados por OpenAI, entrenándolos con artículos de noticias propios. Estos sistemas solo están disponibles para ciertos subscriptores, por lo solo una pequeña parte del público ha interactuado con los mismos. Los resultados muestran un gran interés de parte de usuarios, debido a la facilidad de su uso, igualmente, estas herramientas aún suelen cometer errores al responder o en algunos casos no responder del todo. Este estudio es importante para la investigación actual debido a que enseña que los usuarios si muestran interés en herramientas de este tipo, pero que aún gran parte del público no tiene acceso, por lo que es útil realizar más estudios.

La investigación de Sufi et al. [1] consiste en la creación de un chatbot con la capacidad de mantener conversaciones respecto a noticias. El modelo creado fue entrenado en más de un millón de artículos, los cuales puede clasificar, conectar y resumir en tiempo real. La creación de un resumen de un artículo específico toma 9s en promedio y el crear correlaciones entre diferentes artículos 21s en promedio. El chatbot está limitado por su dataset, no tiene la capacidad de buscar afuera del mismo, esto lo limita tanto en posible sesgo que existan dentro del dataset como en poder conversar sobre eventos más recientes o en lenguajes que no sean inglés. En cuanto a esta investigación, muestra un agente extremadamente similar al propuesto, pero con limitaciones importantes que se desean afrontar durante este proyecto.

Sufi [15] realizó otro estudio similar, en el que se diseña y crea un prototipo de un modelo con la capacidad de crear resúmenes a partir de lo pedido por un usuario. El modelo funciona mediante una base de datos de artículos noticieros a

la cuál puede acceder y encontrar los artículos más relevantes a lo pedido por el usuario. Se utiliza Gemini como el modelo LLM, mostrando la capacidad del mismo para esta clase de tareas. Se logra un F1 de 0.97 en encontrar los temas buscados por el usuario, pero no se hace mención de la fiabilidad de los mismos. El estudio es importante debido a que muestra la capacidad de Gemini como herramienta, pero su limitación respecto a datos al día es una diferencia significativa respecto a ParmBot.

II-E. Efecto de los chatbots de noticias

Maniou & Veglis [16] proponen el uso de chatbots para agilizar la transmisión de noticias durante momentos de crisis. Se utiliza un chatbot simple llamado Quriobot, que puede responder a una serie de preguntas predeterminadas, las cuales son alteradas para basarse en preguntas respecto a la pandemia de COVID, este sistema es llamado COVINFO. COVINFO responde a las preguntas con extractos y artículos de la BBC respecto al estado de la pandemia. El estudio muestra una relativa facilidad de crear un sistema de este tipo en caso de emergencia además de que existe un atractivo de parte del usuario final para esta clase de sistemas. La investigación es pertinente debido a que muestra uno de los posibles usos de un chatbot como ParmBot, aunque para atender el nivel de crisis vista es necesario mantener una alta confiabilidad en el sistema.

El estudio de Zarouali et al. [17] explora la forma en la que los usuarios responden a un chatbot en comparación a un artículo de un sitio web. Se experimenta presentándole a los usuarios un artículo con contradicciones obvias y analizando su reacción al leer el mismo. En los resultados se observa que los artículos presentados por un chatbot suelen generar más apoyo y considerarse más creíbles, aún si contienen el mismo contenido que la versión presentada en un sitio web. Este estudio muestra que existe cierto sesgo a favor de la información presentada por un chatbot, por lo tanto, es necesario mayor cuidado al presentarla.

El artículo de Hoque et al. [18] investiga las diferencias entre los chatbots de noticias y los periodistas a la hora de contestar preguntas sobre artículos. El experimento consiste en que los usuarios leen 3 artículos y luego le preguntan a un chatbot o al autor al respecto, tras lo cuál son encuestados respecto a su experiencia. Los resultados muestran que en general los usuarios suelen ser más críticos con los autores, preguntando sobre el origen de cierta información, pidiendo detalles extra y en algunos casos cuestionando su integridad, mientras que el chatbot no recibió preguntas tan críticas. Esta investigación muestra que los usuarios suelen ser menos críticos de los chatbots, mostrando que no necesariamente desean mantener una conversación crítica y profunda con los mismos, esto debe tomarse en cuenta a la hora de analizar la forma en la que los usuarios interactúan con ParmBot.

Zhang et al. [19] analizan la forma en la que diferentes grupos de personas responderían al uso de chatbots de noticias, centrándose en inmigrantes vietnamitas, chinos y locales. Se permite a los encuestados conversar con un chatbot de Copilot respecto a noticias locales sobre vivienda y luego se les

realiza una encuesta respecto a su experiencia. Los resultados muestran que los grupos inmigrantes encuestados suelen hacer preguntas menos analíticas y en basar su opinión en lo dicho por el chatbot. Esta investigación es importante debido a que muestra que es necesario tomar en cuenta el tipo de persona entrevistada a la hora de realizar el experimento.

La investigación de Savgira et al. [20] explora una de las implicaciones importantes no solo para un chatbot de noticias, sino para las noticias en general: Su efecto sobre la división política. Se realiza una revisión sobre la forma en la los LLM sintetizan artículos de periódicos con diferentes sesgos, principalmente en la división republicano contra demócrata presente en Estados Unidos. Se observa que los LLM son buenos en eliminar sesgos moderados, pero no tan efectivos en sesgos más extremos, también se observa sesgo de parte de los LLM, que suelen apoyar medios de izquierda en temas como derechos LGBTQ y derechos reproductivos, pero apoyan a la derecha en educación e impuestos. Esta investigación muestra que los LLM presentan cierto sesgo a la hora de generar resúmenes, esto es importante a la hora de evaluar la capacidad de los mismos de sintetizar artículos de forma neutral y por lo tanto de ser un medio válido para consumo de noticias de forma neutral.

III. METODOLOGÍA

III-A. Ficha Técnica

- **LLM:** Se utiliza Gemini como LLM para el funcionamiento de ParmBot, específicamente Gemini 3.1 Flash Lite, esto debido a que es el modelo con mayor límite de tokens para cuentas gratis gratis, permitiendo al proyecto funcionar sin necesidad de paga.
- **Noticias:** Las noticias son conseguidas a través de la API dada por NewsAPI.ai, esto debido a que permite conseguir noticias según lenguaje, ubicación y tema de forma gratuita.
- **Motor gráfico:** Se utilizará el motor de videojuegos Unity, esto debido a su flexibilidad y simpleza, permitiendo crear animaciones simples para un modelo sin necesidad de programar todo un sistema de animación.
- **Voz:** Se utiliza text-to-speech para que el agente comunique sus resultados con el usuario, específicamente el sistema interno de Windows 11, esto debido a su capacidad para hablar en el lenguaje español.
- **Representación:** Se representa al agente como un avatar de un robot, este habla directamente con el usuario para explicar sus resultados. El robot fue elegido para evitar cualquier tipo de sesgo causado por genero, etnia o cualquier otra representación humana.
- **Plataforma:** Unity es un motor para crear aplicaciones para computadora, por lo que ParmBot funciona exclusivamente en computador. Debido al uso de funciones de Windows, es necesario el uso de este sistema operativo.

III-B. Casos

- **Caso A (ParmBot interactivo):** El usuario mantiene una conversación respecto a noticias con ParmBot. ParmBot será representado por un avatar 2d de un robot amigable,

este robot tiene la capacidad de hablar mediante TTS (la respuesta también aparece en pantalla como texto), pero el usuario solo puede responder mediante texto. Las animaciones del robot son extremadamente simples, solamente es un ciclo de abrir y cerrar la boca al hablar (sin lip sync).

- **Caso B (ParmBot simple):** El usuario mantiene una conversación con ParmBot mediante una texto, sin que exista ninguna clase de personificación del agente. En esta versión no solo se elimina el avatar de robot, sino que también se elimina la función de TTS, dejando simplemente una conversación de texto. Se elimina la capacidad de realizarle preguntas al agente, solamente se puede dar un tema y se recibe un resumen con fuentes.

El objetivo de esta comparación es observar el efecto de la interacción usuario-agente. La condición B elimina la interacción con ParmBot. Este aislamiento permite ver el efecto de la interacción con el agente, incluyendo su capacidad de conversación, su personificación y su voz.

III-C. Matriz de consistencia metodológica

Cuadro I: Matriz de consistencia metodológica

RQ	Variable	Instrumento	Tarea
1	Compromiso del usuario	Test UES-SF	El participante utiliza ParmBot por aproximadamente 5 minutos, tras lo cual realiza el test UES-SF para medir su nivel de compromiso.
2	Utilidad Percibida	Test TAM3	El participante utiliza ParmBot por aproximadamente 5 minutos, tras esto, realiza el test TAM3 para medir la utilidad percibida del agente

III-D. Justificación de HCI

El uso de un avatar robot se sustenta en la investigación de Straßmann & Krämer [21], donde se encuentra que el uso del robot genera un efecto positivo sobre la utilidad percibida y la atracción estética, dos métricas importantes para los cuestionarios que se realizarán.

En cuanto al uso de voz, Voorveld et al. [22] realizaron un estudio en el efecto del uso de TTS sobre la percepción del usuario respecto al agente. El estudio concluye que la voz tiene un efecto positivo sobre el compromiso del usuario y vuelve al agente más persuasivo, métricas importantes para los cuestionarios que se aplicarán.

IV. FUNCIONAMIENTO DEL AGENTE




Figura 1: Diagrama de ParmBot al recibir un tema de conversación




Figura 2: Diagrama de ParmBot al recibir una duda

El prototipo del agente está completamente implementado, aunque aún se pueden mejorar sus funciones y pueden existir errores en el código que no se han encontrado.

El sistema tiene 2 casos de interacción, el primer caso ocurre al preguntar por un tema de conversación al principio de la interacción. Este caso es descrito en la Figura 1.

El segundo caso se da cuando ya el tema fue elegido y simplemente se le pide a ParmBot resolver una duda. Este es descrito en la figura 2.

En cuanto a una lista de funciones:

- **Búsqueda de noticias:** ParmBot tiene la capacidad de recibir una string de texto a partir de la cuál pide un máximo de 5 artículos utilizando la API de NewsAPI.ai. Estos artículos son del último mes y escritos en español.
- **Generación de resúmenes:** Al recibir artículos de NewsAPI.ai, ParmBot los envía a Gemini junto a sus palabras clave y le pide a este que genere un resumen, al presentar el resumen al usuario se citan las fuentes.
- **Resolver dudas:** Tras recibir el resumen, el usuario puede continuar interactuando con ParmBot para resolver dudas. ParmBot las resuelve enviándole la conversación y los artículos a Gemini y pidiéndole que responda a

partir de lo visto en los artículos, disminuyendo las alucinaciones.

- **Uso de TTS:** ParmBot tiene la capacidad de leer todo lo que dice mediante el TTS nativo que es incluido en Windows 11. Específicamente se utiliza la voz *Microsoft Sabina Desktop*, la cuál es parte del paquete de lenguaje Español (México).

IV-A. El estudio

Se realiza una prueba piloto, esto debido a que el agente está en una etapa de funcionamiento muy temprana y se considera pertinente hacer pruebas con usuarios reales para decidir formas de mejorar al mismo. Por otro lado, estos usuarios nos permitirán obtener una pequeña muestra del compromiso y aceptabilidad del agente en su versión con interacción, contestando las preguntas de investigación del proyecto. Las pruebas serán realizadas en modelo entre-sujetos, las personas entrevistadas solo utilizarán uno de los 2 casos del agente, esto debido a que realizar cuestionarios y pruebas para los 2 casos podría resultar agobiante para los sujetos.

Se realiza la prueba piloto utilizando a un grupo de estudiantes de la ECCI, tomando a 6 estudiantes de Computación como muestra. Estos estudiantes fueron divididos 50/50 entre los 2 casos del experimento y serán elegidos bajo muestreo a conveniencia. Fueron reclutados buscando personas en tiempo libre en el edificio de la ECCI.

El manejo de fallos técnicos se basó principalmente en el uso de una computadora con las instalaciones y configuraciones necesarias para correr el agente. El agente se basa en uso de APIs de modelos online, por lo que no es posible realizar manejo de errores a las mismas más allá de tener un espacio con acceso a internet.

Una vez realizada la prueba piloto, los sujetos respondieron un cuestionario en la forma de un Google Forms con el siguiente formato: Consentimiento Informado, test UEQ-SF y test TAM3 en orden. Los sujetos terminaron el cuestionario en el espacio de la prueba piloto, esto para responder dudas respecto a preguntas del cuestionario y para garantizar que si respondieran por completo el cuestionario.

Los sujetos fueron aceptados o excluidos según los siguientes criterios:

Criterios de Inclusión:

- Estudiante de la ECCI.
- Capacidad de utilizar una computadora y manejo del español.
- Disponibilidad para realizar la prueba y el cuestionario posterior.

Criterios de exclusión:

- Participó en las pruebas piloto realizadas durante la creación del agente.
- No es estudiante.
- Tener conocimiento del funcionamiento o proceso de creación del agente.
- No finalizar la prueba.

IV-B. Métricas

Se midieron el compromiso del usuarios utilizando el Test UES-SF (RQ1) y la utilidad percibida mediante el test TAM

(RQ2). Estos se relacionan con las preguntas de investigación debido a que miden directamente las variables mencionadas en las mismas.

IV-C. Instrumentos Utilizados

El Test UES-SF (User Engagement Scale - Short Form) fue elegido debido a que mide el compromiso del usuario, una de nuestras variables objetivo, la versión SF fue elegida debido a que evitaría el cansancio que se puede generar en cuestionarios muy largos. Este test es descrito en un artículo por O'Brien et al. [23], donde especifican las 12 preguntas y la forma de calcular el resultado final del cuestionario. Este test será administrado al final de la sesión, cuando el usuario haya terminado de interactuar con el agente.

El test UES-SF se divide en las siguientes secciones:

- **Atención Enfocada (FA):** Que tanto capta la atención el proceso de utilizar la herramienta.
- **Usabilidad Percibida (PU):** Que tan útil le parece la herramienta al usuario.
- **Atractivo Estético (AE):** Que tan bien se ve la herramienta visualmente.
- **Factor Recompensa (RW):** Que tan satisfactorio es el proceso y resultado de utilizar la herramienta.

El Test TAM (Technology Acceptance Model) será utilizado para medir que tan útil se considera la herramienta para los usuarios, se usará específicamente la versión 3 del test (TAM3) debido a que es la versión más reciente. TAM3 es descrito en un artículo por Venkatesh & Bala [24], donde explican el diseño de las preguntas y la forma de calcular los resultados. El test se compone de 37 afirmaciones que son respondidas con un número del 1-7 dependiendo de que tanto las apoya el usuario. Las secciones de *Computer Self-Efficacy (CSE)*, *Perceptions of External Control (PEC)*, *Computer Playfulness (CPLAY)*, *Computer Anxiety (CANX)*, *Objective Usability (OU)*, *Subjective Norm (SN)*, *Voluntariness (VOL)*, *Image (IMG)* y *Use (USE)* serán excluidas debido a que no son relevantes para una prueba piloto dentro de un grupo de estudiantes de computación. Las secciones de *Job Relevance (REL)* y *Behavioral Intention (BI)* serán adaptadas al contexto, esto debido a que son importantes pero están escritas para un contexto de uso industrial, no personal. Se eliminan las preguntas PEOU1, ENJ3, REL2, REL3, BI2 y BI3 para evitar repetición y acortar el test. Estos cambios resultan en un test de 14 preguntas.

El test TAM3 modificado se divide en las siguientes secciones:

- **Usabilidad Percibida (PU):** Que tan útil le parece la herramienta al usuario.
- **Facilidad de Uso Percibida (PEOU):** Que tan fácil es utilizar la herramienta para el usuario.
- **Disfrute Percibido (ENJ):** Que tanto el usuario disfrutó utilizar la herramienta.
- **Calidad del Resultado (OUT):** Que tan buenos fueron los resultados para el usuario.
- **Relevancia (REL):** Que tan importante es el caso de uso de la herramienta.
- **Intención Conductual (BI):** Que tan probable es que el usuario use la herramienta en el futuro.

IV-D. Protocolos de interacción

IV-D1. Escenario 1: El escenario 1 se basa en un estudiante que estuvo ocupado durante y no pudo ver los partidos del mundial de fútbol, por lo que pregunta a ParmBot sobre el tema para poder ponerse al día con el resultado de los partidos y resolver dudas respecto a los partidos. El entrevistador lee el consentimiento informado y presenta un pequeño tutorial de como utilizar ParmBot

El usuario debe realizar las siguientes acciones:

- El usuario abre ParmBot, recibe el saludo básico de ParmBot.
- Le escribe a ParmBot Resultados del mundial de fútbol".
- El usuario escribe de nuevo, preguntando quienes fueron los goleadores de los partidos.
- El usuario pregunta el estado actual de los grupos.

Se estima una duración de unos 2 minutos tomando en cuenta el tiempo necesario para que ParmBot lea su resumen. Se esperan los siguientes resultados:

- ParmBot recibe el tema a buscar y, tras unos segundos, responde con un resumen de los eventos basándose en las noticias encontradas, lee el resumen utilizando TTS.
- Para las preguntas, ParmBot se basa en los artículos dados para generar una respuesta y lee la misma utilizando TTS.

IV-D2. Escenario 2: El escenario 2 se basa en un estudiante que ha estado con carga académica considerable, lo que ha evitado que se mantenga al día con la lucha respecto a la Ley de Armonización del Sistema Eléctrico Nacional presentada en la asamblea. Decide utilizar ParmBot para poder informarse de forma rápida respecto a lo ocurrido. El entrevistador lee el consentimiento informado y presenta un pequeño tutorial de como utilizar ParmBot

Se realizan las siguientes acciones:

- El usuario abre ParmBot, recibe el saludo básico de ParmBot.
- Le escribe a ParmBot "Ley de Armonización del Sistema Eléctrico Nacional".
- El usuario escribe de nuevo, preguntando cuales fueron los resultados del primer debate en la asamblea.
- El usuario pregunta "¿Quiénes apoyan esta ley?".
- El usuario pregunta "¿Qué efectos puede tener esta ley sobre las tarifas eléctricas?"

Se estiman 3 minutos para poder realizar este escenario.

Se esperan los siguientes resultados:

- ParmBot recibe el tema a buscar y, tras unos segundos, responde con un resumen de los eventos basándose en las noticias encontradas, lee el resumen utilizando TTS.
- Para las preguntas, ParmBot se basa en los artículos dados para generar una respuesta y lee la misma utilizando TTS. ParmBot debe mostrar puntos de vista que apoyen y que estén en contra de la ley.

V. RESULTADOS Y DISCUSIÓN

Solamente fue posible realizar la prueba piloto con 6 estudiantes de la ECCI. 3 de estos utilizaron ParmBot con

capacidades de interacción y 3 utilizaron la versión sin avatar y sin interacción.




Figura 3: Diagrama de cajas de AE según caso




Figura 5: Diagrama de cajas de PU según caso




Figura 6: Diagrama de cajas de RW según caso




Figura 4: Diagrama de cajas de FA según caso




Figura 7: Diagrama de cajas del resultado final de UES según caso

Las figuras del test UES-SF muestran igualdad en las métricas de Utilidad Percibida (Figura 5) y Factor Recompensa (Figura 6, pero muestran una ligera mejora a favor del caso A (ParmBot interactivo) en Atractivo Estético (Figura 3), Atención Enfocada (Figura 4). En total, el caso A muestra un resultado promedio más alto en el resultado final, como puede verse en la Figura 7.




Figura 8: Diagrama de cajas de BI según caso




Figura 10: Diagrama de cajas de OUT según caso




Figura 11: Diagrama de cajas de PEOU según caso




Figura 9: Diagrama de cajas de ENJ según caso




Figura 12: Diagrama de cajas de PU según caso




Figura 13: Diagrama de cajas de REL según caso




Figura 14: Diagrama de cajas del resultado final de TAM3 según caso

El cuestionario TAM3 modificado muestra resultados favorables para el caso A en las métricas de BI (Figura 8), ENJ (Figura 9), OUT (Figura 10) y PU (Figura 12). Se presentan resultados igualados en REL (Figura 13), pero con menor variabilidad en el caso A. El caso B muestra mejores resultado en PEOU (Figura 11). Esto se resumen en un mejor resultado final favorable al caso A para todo el test TAM3, como se ve en la Figura 14.

VI. CONCLUSIONES

En cuanto a la RQ1, los resultados del cuestionario UES-SF enseña que nuestra muestra presentó resultados favorables a la presencia de interacción con y personificación de ParmBot. Los resultados señalan a que la presencia de interacción no cambia la utilidad percibida por los usuarios, pero la mejora en atractivo estético mejora el compromiso del usuario con la herramienta.

El cuestionario TAM3 también muestra resultados favorables para ParmBot interactivo, el caso B solamente superó

al caso A en PEOU, lo cuál puede explicarse con que la complejidad agregada por la interacción hace que ParmBot interactivo se sienta más difícil de utilizar. El resultado final es favorable al caso A, se da incluso menos traslape entre sus cuartiles centrales (Figura 14 que en los resultados de UES-SF. Todo esto señala a que la presencia de interacción mejora la aceptabilidad de ParmBot para el usuario.

Los resultados del pequeño piloto son similares a los encontrados en trabajos anteriores. Se repiten los resultados de los artículos de Straßmann & Krämer [21] y Voorveld et al [22], los cuales muestran que la presencia del avatar y uso de voz tienen un efecto positivo en la opinión de los usuarios respecto a la herramienta.

Es importante tomar en cuenta que el tamaño de la muestra es tan pequeño que no es generalizable para toda la población de estudiante de la ECCI, estos resultados podrían cambiar al darse un muestreo más extenso y por lo tanto las conclusiones de esta investigación son preliminares.

VII. TRABAJO FUTURO

Debido a las limitaciones de tiempo y de recursos, solamente fue posible realizar una ronda de pruebas de piloto y esta se realizó con una muestra extremadamente pequeña (6 estudiantes). Esto limitó no solo la cantidad de mejoras realizadas al agente, sino también la validez y generalizabilidad de nuestros resultados.

El agente muestra muchas limitaciones en su funcionamiento, en un futuro sería pertinente implementar mejoras como:

- **Uso de mejores LLMs:** Actualmente se utiliza la API de Gemini en su versión gratuita, lo cuál limita el agente a usar Gemini 3.1 Flash lite, debido a que es el modelo con mayor límite de requests en la versión gratuita. De no existir una limitación de presupuesto, se podrían utilizar modelos pagados ya sea de Gemini o de los otros LLMs en el mercado.
- **Límite de artículos:** Al buscar artículos se utilizan solamente los que hayan sido publicados en el último mes y los últimos 5, esto debido a las limitaciones de la API de NewsAPI.ai, donde cada artículo cuesta tokens y si tienen más de 30 días de publicación el costo sube. Las limitaciones de presupuesto significan que por el momento se utilizan artículos de 30 o menos días para minimizar el uso de tokens.
- **Mejoras visuales:** Las animaciones del avatar son muy limitadas, en el futuro sería útil agregar lipsync y animaciones al esperar respuestas de Gemini o NewsAPI.ai. El texto aparece de forma espontánea, en vez de ser escrito lentamente para ayudar a la lectura.
- **Mejorar TTS:** El sistema de TTS es muy limitado, usando entonación poco natural y pronunciando incorrectamente en algunos casos, especialmente si se presentan palabras en otros idiomas. En futuras versiones sería útil encontrar mejores sistemas para manejar el TTS.

Actualmente no se tienen planes de expandir el trabajo de esta investigación para crear un artículo científico formal.

REFERENCIAS

- [1] F. Sufi and M. Alsulami, "Ai-driven chatbot for real-time news automation," *Mathematics*, vol. 13, p. 850, 3 2025.
- [2] A. Pozzi, E. Barbierato, and D. Toti, "Cryptoblend: An ai-powered tool for aggregation and summarization of cryptocurrency news," *Informatics*, vol. 10, p. 5, 1 2023.
- [3] G. Sánchez-Muñoz, I. G. Casado, and D. V. Aramburu, "Artificial intelligence chatbots as assistants for media users: The cases of el país and el espectador," *Journalism and Media*, vol. 7, p. 59, 3 2026.
- [4] O. E. Nordberg, P. Okopnyi, and F. Guribye, "Retelling the news: Exploring ai-driven conversational news interactions," in *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. ACM, 4 2026, pp. 1–18.
- [5] L. Ning, Z. Liang, Z. Jiang, H. Qu, Y. Ding, W. Fan, X. yong Wei, S. Lin, H. Liu, P. S. Yu, and Q. Li, "A survey of webagents: Towards next-generation ai agents for web automation with large foundation models," in *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V2*. Association for Computing Machinery, 8 2025, pp. 6140–6150.
- [6] A. Shukla, P. Bhattacharya, S. Poddar, R. Mukherjee, K. Ghosh, P. Goyal, and S. Ghosh, "Legal case document summarization: Extractive and abstractive methods and their evaluation," in *Proceedings of the 2nd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 12th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, Y. He, H. Ji, S. Li, Y. Liu, and C.-H. Chang, Eds. Association for Computational Linguistics, 2022, pp. 1048–1064.
- [7] D. Tam, A. Mascarenhas, S. Zhang, S. Kwan, M. Bansal, and C. Raffel, "Evaluating the factual consistency of large language models through news summarization," in *Findings of the Association for Computational Linguistics: ACL 2023*, A. Rogers, J. Boyd-Graber, and N. Okazaki, Eds. Association for Computational Linguistics, 7 2023, pp. 5220–5255.
- [8] A. Deroy, K. Ghosh, and S. Ghosh, "Applicability of large language models and generative models for legal case judgement summarization," *arXiv preprint arXiv:2407.12848*, 7 2024.
- [9] A. Vogel-Fernandez, P. Calleja, and M. Rico, *esT5s: A Spanish Model for Text Summarization*, 1st ed. SAGE Publications Ltd, 9 2022, pp. 184–190.
- [10] I. F. Compaore, R. Kafando, A. Sabané, A. K. Kabore, and T. F. Bissyandé, "Ai-driven generation of news summaries: Leveraging gpt and pegasus summarizer for efficient information extraction," Preprint, 2024.
- [11] R. Pan, T. Bernal-Beltrán, M. del Pilar Salas-Zárate, M. A. Paredes-Valverde, J. A. García-Díaz, and R. Valencia-García, "Can llms generate coherent summaries? leveraging llm summarization for spanish-language news articles," *Applied Sciences*, vol. 15, p. 11834, 11 2025.
- [12] G. Maheshwari, A. Taploo, and A. R. Khudabukhsh, "NewsLensai: Ner-guided summarization for mitigating hallucination and bias in llm-based news summaries (student abstract)," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 40, pp. 41 305–41 307, 3 2026.
- [13] E. S. Soriano, V. Ahuir, L.-F. Hurtado, and J. González, "Dacsca: A large-scale dataset for automatic summarization of catalan and spanish newspaper articles," in *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, M. Carpuat, M.-C. de Marneffe, and I. V. M. Ruiz, Eds. Association for Computational Linguistics, 7 2022, pp. 5931–5943.
- [14] Z. Zhang, X. Zhang, and L. Chen, "Informing the design of a news chatbot," in *Proceedings of the 21th ACM International Conference on Intelligent Virtual Agents*. Association for Computing Machinery, 9 2021, pp. 224–231.
- [15] F. Sufi, "Just-in-time news: An ai chatbot for the modern information age," *AI*, vol. 6, p. 22, 1 2025.
- [16] T. A. Maniou and A. Veglis, "Employing a chatbot for news dissemination during crisis: Design, implementation and evaluation," *Future Internet*, vol. 12, p. 109, 6 2020.
- [17] B. Zarouali, M. Makhortykh, M. Bastian, and T. Araujo, "Overcoming polarization with chatbot news? investigating the impact of news content containing opposing views on agreement and credibility," *European Journal of Communication*, vol. 36, pp. 53–68, 2 2021.
- [18] M. N. Hoque, A. A. Mahfuz, M. S. Kindi, and N. Hassan, "Towards designing a question-answering chatbot for online news: Understanding questions and perspectives," in *Proceedings of the CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 5 2024, pp. 1–17.
- [19] Y. Zhang, P.-A. Nguyen-Le, K. Singh, and G. Gao, "The news says, the bot says: How immigrants and locals differ in chatbot-facilitated news reading," in *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 4 2025, pp. 1–20.
- [20] P. Savgira, E. Kreiss, and H. Hosseinmardi, "What stays and what goes: Auditing the impact of llm summarization on news partisanship," in *Proceedings of the Extended Abstracts of the 2026 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 4 2026, pp. 1–8.
- [21] C. Straßmann and N. C. Krämer, "A two-study approach to explore the effect of user characteristics on users' perception and evaluation of a virtual assistant's appearance," *Multimodal Technologies and Interaction*, vol. 2, p. 66, 10 2018.
- [22] H. Voorveld, A. Panteli, Y. Schirris, C. Ischen, E. Kanoulas, and T. Lentz, "Examining the persuasiveness of text and voice agents: prosody aligned with information structure increases human-likeness, perceived personalisation and brand attitude," *Behaviour & Information Technology*, vol. 44, pp. 2913–2928, 7 2025.
- [23] H. L. O'Brien, P. Cairns, and M. Hall, "A practical approach to measuring user engagement with the refined user engagement scale (ues) and new ues short form," *International Journal of Human-Computer Studies*, vol. 112, pp. 28–39, 4 2018.
- [24] V. Venkatesh and H. Bala, "Technology acceptance model 3 and a research agenda on interventions," *Decision Sciences*, vol. 39, pp. 273–315, 5 2008.